



端侧算力网络 白皮书 (2022年)

中国移动通信集团终端有限公司、北京邮电大学
中国信息通信研究院、中国通信学会

2022 年 7 月

专家组和撰写组名单

专家组组长

张宏科 中国工程院 院士

撰写组（按单位名称排名）

单 位	姓 名
中国移动通信集团 终端有限公司	汪恒江、崔 芳、倪 茂、 王绍颖、周 婷等
北京邮电大学	王文博、张 兴、张佳鑫、 孙钰坤、胡远林、李 洪、黄昊楠等
中国信息通信研究院	许志远、王骏成

推荐意见

近年来，在“新基建”、“东数西算”等国家政策和工程的指引下，算力的概念成为运营商、互联网企业、设备商和学术机构的热门话题，算力网络也已经成为未来 6G 网络的潜在技术和关键能力。随着物联网、5G/6G、边缘计算、AI 的不断融合发展，各种类型终端特别是智慧型终端的算力显著增强，端侧算力资源在智慧城市、智能家居、智慧养老、智慧农业等垂直领域发挥了重要作用。面向海量泛在异构的终端节点，需要探索和研究端侧算力网络及其使能技术。

算网融合技术在多领域得到高度认同，被广泛视为加速产业数字化升级演进的重要抓手。算网融合围绕“计算网络化”和“网络计算化”两个方向，重点聚焦于算力网络。而近年来终端设备种类和数量飞速增长，终端设备在算力网络中的作用越来越凸显，为了有效地利用泛在的终端设备，亟需提出一种在终端侧延展的算力网络架构——端侧算力网络。

端侧算力网络是算力网络的一个重要分支，但是又不同于常规算力网络，不需要算力应用企业来集中投资建设基础设施，而是在一定的空间内把海量用户终端的空闲算力，通过网络设施进行汇集和组织，直接为终端设备提供泛在的 AI 算力服务。通过端侧算力网络可以将泛在的分布式算力有效汇聚起来，聚沙成塔，成为算力网络中的一个重要算力供给方。

本白皮书着眼于 6G 时代的网络特点和发展趋势，详细地分析了终端的发展现状、基本特征和发展趋势，具体阐释了端侧算力网络的概念、体系架构、功能架构及其主要特征，总结了端侧算力网络的各项关键使能技术，并展望了端侧算力网络在智能家居、智慧医疗、智慧教育、智慧农业等领域的潜在应用场景。

从实际应用的角度看，在算力网络的基础之上进一步构建端侧算力网络，有望真正地实现将分布式的算力充分利用赋能万物智能时代的算力需求的愿景。近些年，终端设备以前所未有的种类与数量融入百姓的生活之中，一方面终端设备所能提供的算力能力日益增强，另一方面，终端设备所能承载的服务越来越多样，移动通信系统的飞速演进也将为终端设备带来越来越多的新功能，未来的终端设备将有望于助力虚拟世界与现实世界的深度融合，而端侧算力网络的建设将使得终端设备展现出更多的新应用。

从技术驱动的角度看，每一项新技术的提出、每一种新型网络架构的出现，都不是孤立演进的，而是需要与相关领域的其他技术协同发展的。从云计算的提出，到边缘计算的出现，直至算力网络的提出，都是源于大数据、人工智能、内生安全等技术的需求和驱动。如今，芯片技术的飞速演进、可穿戴设备、脑机接口等新型终端设备的出现与发展，端侧算力网络及其相关的使能技术将持续且深入地得到探索与研讨。

鉴于端侧算力网络的重要意义和巨大发展潜力，此白皮书有助于

产业界和学术界各方凝聚更多共识，抓住数字经济发展的战略机遇，
助力加快国家算力网络战略、前沿技术和应用的发展！

中国工程院院士、北京交通大学教授

邊兴科

前 言

第六代移动通信系统（6G）和低轨卫星通信系统所引领的新技术浪潮方兴未艾，成为全球众多国家的研究热点。移动通信网络在发展演进中，算力需求的快速增长与分布式泛在算力利用率低效之间的供需矛盾问题日益凸显。面向智能家居、智慧医疗、智慧城市等新型垂直应用场景，分布式多级端侧算力节点资源相对受限且缺乏协同管控能力，导致了端侧算力资源难以得到高效利用；因此如何充分聚合泛在终端的算力资源，是整体实现算力网络体系的重要环节，也是提升网络整体资源利用率的关键。因此，面向网络中海量泛在异构的终端节点，亟需探索研究端侧算力网络及其使能技术。

在算网融合的大背景下，算力网络的概念应运而生。算力网络是针对算网融合发展趋势提出的新型网络架构，通过无处不在的网络将分布各处的计算资源相互连通，通过统一协同调度，使不同的应用能够按需、实时地调度不同位置的计算资源，实现网络和算力的全局优化，提供更高质量的用户体验。在此基础上，端侧算力网络则着眼于泛在终端的算力利用率和计算效率的提升，基于现有的蜂窝网络、无线网络等网络基础设施，解决在分散的、非一致性的设备上的分布式计算、隐私性存储等难题，为用户提供更加智能化的、个性化的应用服务体验。在算力网络中云边和网络的支撑下，端侧算力网络中的分布式多级终端侧算力资源有望得到更好的利用，构建高效的端侧算力体系架构和新型网络范式，实现端侧算力感知、资源虚拟协同、多粒

度算力调度以及安全隐私与可信交易。而端侧算力网络也可助推算力网络实现“网络无所不达，算力无所不在，智能无所不及”的愿景。

本白皮书基于现有的网络基础设施，从“端侧算力的有效利用”的角度出发，提出并系统分析了端侧算力网络的概念内涵，详细总结了终端的发展现状、基本特征和发展趋势；具体阐释了端侧算力网络的概念、体系架构、功能架构及其主要特征；总结了端侧算力网络的各项关键使能技术，并给出了端侧算力网络的应用场景。需要指出的是，本白皮书尚未涉及端侧算力网络对网络基础设施支撑的相关技术要求及其对算力的影响。希望通过本白皮书，加快国家算力网络相关技术和应用的发展，凝聚学术界和产业界共识，推进端侧算力网络技术加快发展并走向商业成熟。

目 录

一、终端的发展背景	1
1.1 终端的发展现状	1
1.2 终端的基本特征	2
1.2.1 智能化不断增强	2
1.2.2 资源受限性	3
1.2.3 算力的差异性	3
1.2.4 泛在分布性	5
1.2.5 通信受限性	5
1.2.6 隐私数据安全性	5
1.3 终端的发展趋势	6
二、端侧算力网络的概念及架构	10
2.1 端侧算力网络的概念	11
2.2 端侧算力网络的体系架构	12
2.3 端侧算力网络的功能架构	17
2.4 端侧算力网络的主要特征	20
三、端侧算力网络的关键技术	22
3.1 层次化端算力感知图模型	22
3.2 面向多终端协同的资源虚拟化技术	23
3.3 多终端协同的数据压缩技术	25
3.4 多粒度多层次端算力调度	25

3.5 面向终端设备的现场级 AI 推理	28
3.6 端算力的定价机制	29
四、端侧算力网络的隐私与安全	31
4.1 认证与鉴权	31
4.2 数据安全保护	32
4.3 可信交易	34
五、端侧算力网络的应用场景	37
5.1 智能家居	37
5.2 智能医疗	38
5.3 车联网	40
5.4 智慧教育	41
5.5 智慧农业	42
六、结束语.....	44
参考文献.....	45
缩略语.....	49

一、终端的发展背景

1.1 终端的发展现状

近年来，随着智能终端硬件技术的快速发展和应用领域的扩大，智能终端呈现多种多样的产品形态，如可穿戴设备、智能家居、IoT 以及车载设备等。其中为主要代表的平板电脑在 2021 年全球销量 1.68 亿部，同比增长 2.9%；智能手机在 2021 年全球总出货量达 16.993 亿部；可穿戴设备 2021 年全球全年出货量为 5.336 亿台，比 2020 年增长 20%。根据统计数据显示[1]，到 2023 年，人均联网设备将达到 3.6 台，高于 2018 年的人均联网设备 2.4 台，同时到 2023 年，将有 293 亿台联网设备，高于 2018 年的 184 亿。由此可见，智能终端产业将长期处于高速发展阶段，而且伴随着智能终端种类的增多，其产业规模和渗透率将会持续扩大。越来越多的非智能设备会进行智能化改造，例如家电、汽车、工业设备等；越来越多的传统行业会进行信息化建设应用智能终端提高生产效率，例如医疗、教育、物流、税务、能源等；这些都将对智能终端技术提出更多的需求。

随着智能业务、沉浸式业务和数字孪生等新业务的不断发展，对网络以及终端都提出了更高的智能化信息处理需求。不同类型的业务和不同的服务需求，数据处理时延和精度的要求不尽相同。随着端侧算力能力的提升，边缘计算技术和芯片技术的发展使得端侧网络能够支撑大量的运算任务，并存在着大量过剩的算力。算力是数字经济与人工智能时代下的生产力，各行各业对数据处理的规模和实效性需求

快速上升，人工智能等产业发展促进了服务的升级，推动了算力向边缘扩展。然而，由于当前终端设备主要起到传感器设备的作用，进行数据感知并将数据上传到云端进行处理，导致当前端侧与云端的算力供给方式利用率不足 15%，算力需求快速增长与泛在算力利用率低的供需矛盾日益凸显，端侧算力技术成为算力基础设施建设的重要组成部分。

目前国内端侧算力相关产业和技术蓬勃发展，信息基础设施建设稳固，通信基础好。终端生态活跃，具有多品牌的异构设备，设备数量规模巨大，极具发展潜力，生态方面，展现出百家争鸣的态势，这也导致设备统一纳管难度比较大，耗时比较长。目前异构多终端，能力协同和纳管也处于研究阶段，没有成熟的产品方案。而当前国际上泛终端生态活跃度落后于国内，针对异构多终端算力、能力协同的研究大多仍然停留在高校的研究阶段，缺少实际落地应用，没有成型的产品与方案。

1.2 终端的基本特征

1.2.1 智能化不断增强

得益于半导体工艺、流程与技术的不断成熟，终端设备芯片中晶体管的数量呈现出爆炸性的增长趋势，使得 CPU、DPU 和 GPU 等处理器的计算性能得到快速的升级，加之 AI 芯片在终端设备的普及性应用，在手机、平板电脑等移动设备终端运用本地化人工智能加速器进行机器学习，实现人物识别、情感分析、APP 垃圾信息处理、分析

用户的设备使用习惯等已成为可能，自动驾驶汽车作为新一代移动终端，引领众多芯片厂商投入算力升级的研究中，英伟达推出的自动驾驶芯片 **Atlan**，单颗芯片的算力便达到 1000TOPS[2]，随着端侧芯片算力的快速升级，相对于边缘计算和云计算来说，终端设备的 AI 计算劣势不再明显。

1.2.2 资源受限性

终端设备通常由电池供电，不具备长时间连接电源的条件，因此终端设备的计算能力常常受限于电池容量的大小，同时由于终端设备体积的限制，终端设备往往无法采用高功耗、高性能的芯片，因此面对计算密集型的任务，单个终端设备往往无法在时效范围内有效地完成任务的处理，虽然终端研制和芯片技术的发展萌发出多种类型的终端算力提供者，但是由于用户业务需求的潮汐效应以及随时间的波动性变化，分布式的终端往往存在大量过剩的算力，无法得到充分地应用。

1.2.3 算力的差异性

如下表所示，终端设备搭载的芯片可提供的算力差异明显，可提供 1TOPS 到几百 TOPS 不等的算力，应用于不同的场景具体表现为，同一生产商同一种类不同型号的芯片具有较大的算力水平差异，同一种类的终端设备也往往搭载不同的芯片，形成泛在终端算力分级的形态，同时，同一芯片进行不同精度的数据处理也具有不同的算力。此外，作为电池供电设备，多样化的终端设备的电池容量具有较大的差

异性，可穿戴设备往往只有 100mAh 容量，扫地机器人等家用电器可达 2000mAh，台式机、电视等非移动终端往往为插电设备，工作时可以一直供电，电池容量的差异性也导致泛在终端有效算力具有非常大的动态变化的差异性。

表 1 芯片的算力差异性对比[3-5]

算力水平	典型芯片	支持数据类型	芯片算力(对应数据类型)	典型应用
0~10 TOPS/TF LOPS	瑞 芯 微 RK3566	INT8	0.8	门禁设备、 考勤设备、 车载终端、 可穿戴设备、智能手机、智能音箱、机器人
	瑞 芯 微 RK1808	INT8	3	
	寒 武 纪 Cambricon-1M-4K	INT8/INT16/INT32	8/4/1	
10~100 TOPS/TF LOPS	华为昇腾 310	INT8 /FP16	22/11	
100~1000 TOPS/TF LOPS	寒武纪思元 270-S4	INT4/INT8 /INT16	256/128/64	智能视频分析、智慧视觉设备
	NVIDIA Tesla T4	INT4/INT8 /FP16/FP32	260/130/65/8.1	

	华为昇腾 910	INT8 /FP16	640/320	
--	-------------	------------	---------	--

1.2.4 泛在分布性

终端设备最为显著的特征是体积小，方便携带，在终端设备嵌入不同功能的传感器、摄像头、以及处理器之后，可以部署在水下、室内的角落、路灯等多种场景中，进而使得终端设备具有泛在部署、分布式的特征，同时，体积较小的终端设备也具有方便携带移动或者自移动的特性。

1.2.5 通信受限性

数据到边和云的时延远远大于终端之间的时延，终端设备具有处理面向超低时延通信的业务的优势[6]，此外，很多终端设备，例如：蓝牙耳机、智能音箱、智能电冰箱等终端设备不具备接入蜂窝网络的能力，无法直接与基站建立通信链路，进而导致无法将算力任务直接调度至边缘服务器。

1.2.6 隐私数据安全性

边缘计算将计算资源下沉到网络边缘靠近用户的位置，虽然在一定程度上缩短了数据在网络中的传输距离，有效地降低了数据在传输过程中隐私泄露的风险，但是边缘计算节点获取的业务数据，仍然包含了诸多未脱敏的隐私数据，边缘计算很难从根源解决用户数据的隐私和安全问题[7]。终端设备可以在本地处理用户的隐私数据，无需将数据上传至边缘节点或者中心云进行处理或者存储，可以从源头保护

用户的隐私，在智能家居场景中，用户佩戴的智能手表、使用的智能音箱、家中的扫地机器人等终端设备产生的视频、图像、语音、音乐偏好、健康状况等隐私数据，都可以在家庭中的终端设备进行处理，保证数据的安全性。

1.3 终端的发展趋势

未来终端将向多样化、智能化、复杂化方向发展。6G 网络时代将从“智能外加”转向“智能内生”，构建实现感知、分析、反馈的闭环，提供无处不在的智能服务。终端也将越来越多样化，智能化，交互方式更加复杂，人机交互、数字孪生、脑机接口带来数据处理的复杂度增加。首先，消费者可以使用的终端产品越来越多样化。当前出现的终端可以有多种分类方式，从行业应用分，终端设备可以分为工业设备检测终端，设施农业检测终端，物流 RFID 识别终端；从使用场合分，终端设备可以分为固定终端，移动终端和手持终端；从使用扩展性分，终端设备又可以分为单一功能终端和通用智能终端；从传输通路分，终端设备还可以分为数据透传终端和非数据透传终端。同时，终端的智能程度也在不断提高，人机交互的方式不断变革，从利用鼠标、键盘向设备输入指令到触摸屏技术的出现进一步优化了人机交互的方式，再随着语音识别技术，以及生物识别技术的发展，一些前沿的人机交互方式已经出现，比如通过语音向设备发送指令。更为前沿的人机交互比如眼球操作，手势操作，甚至脑波控制也已经实现，这些技术让终端和人的联系更加紧密。其次，AI 算力在终端的应用

日益增强，传统而言，很多对神经网络的训练和推理都是在云端或者基于服务器完成。随着终端处理器性能的不不断提升，通信技术演进所能带来的完整可靠性以及随着智能终端多样化的演进趋势，很多人工智能的推理工作，如模式匹配、建模检测、分类和识别等逐渐从云端转移到了终端侧。AI 计算场景和算力持续向终端迁移，是智能终端 AI 芯片产业发展的内在驱动力。

2018-2023年中国智能商用终端市场规模预测趋势图




图 1 中国智能终端市场发展趋势

终端操作系统越来越开放，多样化。由于不同的设备，终端智能化的重点不同，因而对操作系统的需求不同，操作系统的功能也不同。比如用于智能家居的中控系统，要求具有强大的处理功能，为此谷歌在 2015 年推出了物联网操作系统 Brillo；在智能冰箱，智能空调等终端，需要有一定的处理能力，所以它们的操作系统一般是由传统的操作系统进一步裁剪；还有很多终端设备，它们主要传输简单的感知信息，因此它们的内存容量通常仅仅几 K。可以看出，终端设备的应用领域不同，决定了物联网操作系统的多样性。而终端设备在不同应用

领域的发展也推动了终端操作系统的多样化发展。

多终端协同的技术越来越成熟，终端之间的联系越来越紧密，由于计算本身的需求推动，计算从云端建模-终端使用转变为终端侧的推理与计算处理。iOS、安卓、鸿蒙的分布式、多终端协同能力将进一步增强，手机作为主设备，将持续增强与办公终端、智家终端、XR设备、车机等协同交互与共享的能力。目前，华为，小米，联想都推出了自己的多终端协同的产品，突破了 Android 与 Windows 跨平台交互的难题。随着泛终端的自主智能能力不断升级，端云协同、能力虚拟共享、服务流转等将成为基础性能力。硬件能力方面，算力能力显著增加，AI 处理能力的芯片逐步成为研发重点。终端基础硬件性能不断优化，算力增速越来越快。据 IDC 预测数据，2025 年全球物联网设备数将超过 400 亿台，产生数据量接近 80ZB，且超过一半的数据需要依赖终端或者边缘的计算能力进行处理。中国信息通信研究院发布的《中国算力发展指数白皮书》中显示,预估未来五年全球算力规模将以超过 50%的速度增长，到 2025 年整体规模将达到 3300EFlops。智能硬件终端的领域包含的范围甚广，现阶段智能家居设备、智能机器人、智能车载设备、智能医疗设备、智能可穿戴设备、智能大屏设备、智能安防设备等细分场景领域都有较好的落地和应用，每个领域的产品品类都很丰富。有数据显示[8]，“万物智能”时代的物联网将拥有 10 万亿美元的市场空间，按照硬件占比 20%-30%来计算，智能硬件设备的潜在市场空间约 2~3 万亿美元。用户需求的不断

提高也将推动终端算力的迅猛发展，协同基础硬件不断优化。

云终端市场规模不断实现新突破，随着云计算技术的持续演进和各行业上云的进程不断加快[9]，云终端产品进一步优化，社会对云终端的认知度和接受度提高，云终端市场需求将逐渐释放，市场规模保持持续增长的态势。预计未来五年，中国云终端市场将以 31.7% 的复合增长率发展，到 2025 年，中国云终端市场规模达到 73.45 亿元[10]。未来终端之间连接将更加立体泛在，多终端协同技术的成熟将推动终端之间的联系更加紧密，终端之间不再像从前相互独立，各自独立完成自己的任务而是相互影响，协同，合作。这种技术的发展将会进一步优化终端生态系统，提升业务的服务质量和人的生活质量。

二、端侧算力网络的概念及架构

在通信网络与计算的发展演进中，算力需求的快速增长与分布式泛在算力利用率低效之间的供需矛盾问题日益凸显。如何充分利用泛在终端的算力资源，是提升网络整体资源利用率的关键。分布式多级端侧算力节点资源相对受限且缺乏协同管控能力，导致了端侧算力资源难以得到高效利用。因此，面向海量泛在的终端节点，开展端侧算力网络（TCAN）的研究与应用是实现整体算力网络的重要环节之一。

端侧算力网络的核心价值是充分利用分布式多级端侧算力资源，建立适合的体系架构，设计高效的资源利用方法，从而提高系统的服务效率。区别于算力网络中云边端三者相互协同，端侧算力网络侧重一定空间内终端设备之间的协同，在区域空间内构建计算网络，直接为终端设备服务，由于终端设备之间的距离远远小于端和云边之间的距离，端侧算力网络可以大大缩短服务的响应时间，为人类提供更加优质的服务。

对端侧算力网络的研究既包括从网络视角出发，讨论网络支撑算力的相关命名、寻址、转发及组网等关键技术要求及其对算力的影响；又包括从端侧算力的有效利用的视角出发，基于现有的网络基础设施，解决在分散的、非一致性的设备上的分布式计算、隐私性存储等难题。本白皮书着眼于后者，关注于终端计算效率的提升，为用户提供更加智能化的、个性化的应用服务体验，并在这个视角下给出端侧算力网络的概念、架构及主要特征。

2.1 端侧算力网络的概念

端侧算力网络是通信网络和终端设备深度融合和进一步发展的新型物联网架构，面向空间内和跨空间的网络场景，利用现有的多种通信技术如蓝牙、WIFI、Zigbee、5G、D2D、Lora等，通过动态自治组网连接分布各处的终端设备，并通过实现面向终端协同的资源虚拟化，构建层次化算力感知图，以及多粒度多层次的资源调度与跨空间的算力协同等关键技术，构建可以充分利用终端设备能力的全新环境，保证网络能够按需实时调度不同位置终端设备闲置开放的计算资源和硬件能力，提高无线网络和终端设备算力的利用率和业务的QoS，进一步缩短服务响应时间和处理时延，提升用户体验。




图2 算力网络体系架构图

在算力网络中，云、边、端共同构成了多层立体的泛在算力架构

[11]。网络作为连接用户、数据和算力的桥梁,通过与算力的深度融合,共同构成算力网络的新型基础设施[12]。算力网络中,云和边的算力被着重强调和利用,而端往往被看做是产生业务的算力使用者。端侧算力网络则重点关注终端算力的利用,在算力网络中云边和网络的支撑下端侧算力网络中的终端算力可以更好的得到利用以及与云边协同。

因此,图 2 所示,端侧算力网络是算力网络的重要组成部分。虽然两者都是将算力和网络相互融合,但是存在一定的差异,所以端侧算力网络又不同于算力网络。端侧算力网络中空间内多终端协同的场景已经出现,手机作为主设备,办公终端、智家终端、XR 设备、车机等协同计算、交互与共享,云终端可利用端侧算力网络,将端侧算力、存储就近迁移端侧算力网络中,将操作系统、应用程序都运行在端侧算力网络中,未来空间多终端协同的能力将进一步增强,空间多端协同的含义将进一步开放,不仅仅是功能的协同,而且终端设备将进一步和网络融合,实现算网协同、多端协同。

2.2 端侧算力网络的体系架构

如图 3 所示,端侧算力网络架构从算力构成来看,可分为终端层和网络层。

在端侧算力网络基础设施中,泛在分布式的终端设备是端侧算力网络的重要组成部分,在智能家居环境中,智能终端设备包含智能冰箱、智能门锁、智能摄像头、智能电视、智能冰箱、扫地机器人、智




图3 端侧算力网络体系架构图

能窗帘、烟雾警报设备等；在办公园区中，智能终端设备主要包含智能台灯、打印机、手机、平板电脑、笔记本电脑、台式机等，可穿戴的智能终端设备主要包含智能手环、VR眼镜、多功能耳机、心率监控设备、人体微动监控设备等；在车联网中，智能终端设备主要包含自动驾驶车辆、路侧摄像头、智能红绿灯、车载娱乐终端设备等。

基于端侧算力网络移动特性、分布特性及组网特性，可以分为时空高度动态组网、室内泛在大连接组网、多协议动态自治组网、多层次算力智能调度四种端侧算力网络形态。

时空高度动态组网：端侧算力网络中，大部分终端设备具备可移动性，如上图所示，由自动驾驶车辆移动终端组成的车辆终端侧算力网络，在 t_1 和 t_2 时刻，车辆终端的移动性使车辆终端侧算力网络拓扑处于高度的动态变化之中。

室内泛在大连接组网：现在，几乎所有的生活设备都被赋予了智慧化的能力，具备一定数据感知、数据处理能力，这些泛在的终端设备通过无处不在的连接组成端侧算力网络，呈现出泛在大连接的组网形态，如上图所示，家庭中的智能冰箱、智能门锁、智能摄像头、智能电视、智能冰箱、扫地机器人、智能窗帘、烟雾警报设备不再只是独立运行，承担某一项特定的功能，而是作为一个泛终端在端侧算力网络中与其他设备协同运行。

多协议动态自治组网：终端设备之间可以采用短距离通信技术进行设备综合能力评估值的通告以及任务的转发调度，智能台灯可以使用低功耗的 ZigBee 技术与台式机建立算力信息通告以及算力任务调度的连接，笔记本电脑与台式机之间可以接入同一个 WiFi 进行算力组网，打印机与手机之间可以通过蓝牙技术传输算力信息，此外还可以使用 D2D、超宽带（UWB）技术组建多协议动态的终端算力自治网。所有分布式的智能终端设备可以感知自己的实时存算能力、剩余电量、任务处理需求，根据设备归属者的意愿以及设备的综合能力评估值选择将自己的终端设备加入端侧算力网络中（入网）或者将自己的终端设备退出端侧算力网络中（退网），如上图所示，具有较强的存算能力

且有较多的剩余电量的智能手机可以选择入网，使得设备的算力资源得以充分利用，电量不足的平板电脑可以选择退网，降低自己的电量损耗。

多层次算力智能调度：泛在化的终端设备往往具有不同等级的任务计算能力、数据存储能力，例如在办公园区中，终端设备的存算能力等级通常为智能台灯<打印机<手机<平板电脑<笔记本电脑<台式机，与此同时，终端设备的存算能力随着业务负载状态的变化处于动态变化的状态。同时，在端侧算力网络中，大部分终端设备为电池供电设备，终端设备剩余的电量也处于实时的变化状态。具备不同算力能力的终端设备可以通过端侧算力网络实现智能地算力共享，如上图所示，算力能力较低的智能台灯可以向智能网关发起算力请求，智能网关基于一定的算力共享策略将智能台灯的算力任务发送至台式机进行处理。

根据覆盖范围的不同，端侧算力网络可以分为场域终端算力网、局域终端算力网、异域终端算力网三种不同规模的端侧算力网络。

场域终端算力网：如上图所示，家庭 1， 家庭 2， 家庭 3， 公司 1， 公司 2 中的泛在终端设备分别基于多种短距离通信协议构建成一个空间场景内的终端算力网，每一个时刻马路上一定范围内的智能终端也可以构建成一个场域终端算力网，在自场域端侧算力网络中，具有算力需求的终端设备可以在场域终端算力网内发布算力需求信息，最终基于算力编排策略将任务迁移到场域终端算力网内的其他终端进行协同处理。

局域终端算力网：同一个边缘代理管控范围内的多个不同的场域终端算力网可以组成一个局域终端算力网络，如上图中不同的颜色块所示，不同的家庭中的智能家居设备由于算力归属者不同、通信范围受限等因素无法形成场域终端算力网，但是同一栋楼的多个家庭可以形成一个局域终端算力网，每一个家庭可以评估自己的所有智能家居设备的综合能力，并将算力能力实时上报给边缘代理服务器，当局域终端算力网出现无法有效地处理自身的任务请求的情况时，1）可以通过智能网关设备将局域终端算力网的算力请求发送至边缘代理服务器，边缘代理服务器在局域终端算力网中做出智能算力调度决策，将决策信息发送至需要算力资源的局域终端算力网的智能网关，2）也可以通过智能网关从边缘代理服务器获取局域终端算力网中所有场域终端算力网的综合算力评估信息，然后做出智能算力调度决策。

异域终端算力网：连接不同的边缘代理服务器的局域终端算力网组成异域终端算力网，即泛在的端侧算力网络。由于终端设备的数据往往包含使用者的敏感信息，因此终端的算力交易往往会选择可信终端，如上图所示，当家庭中的某些终端设备算力不足时，需要选择其可信终端设备——在外面的家庭用户的手机，则需要通过网络层进行跨网的异域终端算力调度。

2.3 端侧算力网络的功能架构




图 4 端侧算力网络接口示意图

如上图所示，端侧算力网络控制层是属于终端设备的一个模块，为南北两侧提供中介。端侧算力网络控制层通过南向接口接入具有异构性的操作系统如 Linux、Android、windows、iOS、HarmonyOS 等。这些基础操作系统为上层端侧算力网络控制层的应用功能提供基础的系统调用支持。同时，端侧算力网络控制层本身通过端侧算力网络互联互通，是整体端侧算力网络的一个原子单位，结合人工智能与大数据技术，实现对资源的虚拟化、算力结构、算力调度和统一编排，为北向接口的应用服务提供功能 API，为实现对于用户智能无感的应用服务奠定基础。




图 5 端侧算力网络功能架构图

端侧算力网络从功能架构上分为设备层、资源层、基础操作系统、编排调度层、应用组件、应用服务以及安全与隐私，如上图所示。

1. 设备层

快速增长的终端设备数量和繁多的终端设备种类为端侧算力网络提供了大量潜在的泛在算力，是端侧算力网络组建的关键。终端设备承载了上层的应用服务，是端侧算力网络为用户提供服务的基础。

2. 算网资源层

算力网络资源层是端侧算力网络的坚实底座。以高效能、集约化、

绿色安全的新型一体化基础设施为基础，形成泛在的分布式算力体系，满足现场级的算力需求，网络资源实现端算力高速互联，满足数据高效、无损传输需求。用户可以随时随地按需地通过无所不在的网络接入无处不在的算力，享受算力网络的极致服务。

3. 基础操作系统层

基础操作系统为上层的应用功能提供基础的系统调用支持。虽然基础操作系统多种多样造成了终端设备在操作系统上具有异构性，但是也为终端设备适应不同场景的需求提供了底层支持。

4. 编排调度层

编排调度层是端侧算力网络的调度中枢，通过将端侧算网原子能力灵活组合，结合人工智能与大数据技术，向下实现对算网资源的虚拟化、算力解构、算调度和统一编排，提升端侧算力网络效能，向上提供端侧算网调度能力接口和服务编排管理能力，支持端侧算力网络多元化服务。

5. 应用组件层

在应用层和编排调度层之间增加了应用组件层，实现了资源和服务的解耦，同时，各种智能化组件也为应用服务层的提供了可调用的智能 API，为实现智能无感的应用服务奠定基础。

6. 应用服务层

应用服务层为用户提供服务，是端侧算力网络的服务和能力提供平台，通过算力网络原子化能力封装并融合多种要素，实现算网产品

的一体化服务攻击,使用户享受便捷的一站式服务和智能无感的体验,同时通过利用社会多方算力,结合区块链等技术构建可信算网服务统一交易和售卖平台,提供算力电商等新模式。

7. 隐私和安全

端侧隐私和安全技术是以算网自身安全能力为基础,以智能分析、灵活编排为手段,形成主动免疫、协同弹性的安全能力,满足网络行为可预期、强管理、差异化的安全需求,主要借助安全算力编排技术,高安全隔离技术、算力安全对抗技术等,构建算力网络安全体系,实现端侧算力网络的自免疫能力。

2.4 端侧算力网络的主要特征

1. 自治组网

终端设备之间主要靠无线链路相互通信,所以它们之间的网络主要靠自治组网。

2. 时空高动态性

由于终端设备具有移动性,终端设备的位置在时间和空间两个维度上都存在动态性[13],而且终端设备的算力同样存在时空高动态性,那么端侧算力网络就需要兼顾这些动态特征。

3. 多层次多级端算力

端侧算力网络中终端设备之间的差异性较大,在组网的时候呈现多层次多级别的特点。

4. 归属多样性

端侧算力网络根据终端设备的归属往往属于不同的业主，公司，具有归属多样性。

5. 强安全隐私

由于终端设备的归属多样性，且数量大，隐私泄露定位与安全问题的排查量大，所以需要确保端侧算力网络的强安全隐私性[14]-[15]。

6. 交易定价多方参与

端侧算力网络中的设备归属个人或企业，端侧算力的交易将会涉及到不同的设备归属方，这时它们之间的交易定价往往具有多方参与的特点[16]。

7. 多维度泛算力度量建模

终端设备的算力信息具有多维度的特点，主要包括计算资源总量、计算资源使用量、存储资源总量、存储资源使用量、电池剩余量、通信范围、数据感知能力、移动速度、移动方向等等，需要在多个维度对终端设备进行泛算力度量建模来为任务调度提供先验信息。

8. 感知能力面向用户

终端设备是业务出现的源端和结果展示的终端，其感知能力直接面向用户，而算力网络中的边缘和云则是任务处理的中转站，其感知能力主要面向资源需求。

三、端侧算力网络的关键技术

本章中，我们从端侧算力的有效利用的角度总结了一些目前普遍关注的端侧算力网络各项关键使能技术，包括层次化端算力感知图模型、面向多终端协同的资源虚拟化技术、面向多终端协同的数据压缩技术、多粒度多层次端算力调度、面向终端设备的现场级 AI 推理、端算力的定价机制等内容。而网络如何更好的支撑端侧算力、网络对端侧算力的影响等相关的技术内容在本白皮书中尚未涉及，留待进一步讨论。

3.1 层次化端算力感知图模型




图 6 层次化算力感知图模型

终端设备的算力信息影响因素主要包括计算资源总量、计算资源使用量、存储资源总量、存储资源使用量、电池剩余量、通信范围、数据感知能力、移动速度、移动方向、微服务实例、隐私保护度，为

了使能端侧算力网络进行实时、有效地算力调度，构建终端设备的算力特征向量 $A=[\text{计算资源剩余量}, \text{存储资源剩余量}, \text{电池剩余量}, \text{通信能力}, \text{数据感知能力}, \text{移动模式}, \text{微服务匹配度}, \text{隐私保护度}]$ ，根据终端设备的特征向量评估终端设备的综合算力值 $X=a \times \text{计算资源剩余量} + b \times \text{存储资源剩余量} + c \times \text{电池剩余量} + d \times \text{通信能力} + e \times \text{数据感知能力} + f(\text{移动模式}) + L(\text{微服务匹配度}) + Y(\text{隐私保护度})$ 。进而通过聚类算法可以将终端设备基于算力度量值进行层次化分组，如图所示可以分为三级算力设备，第三级终端设备在自组织网内进行端到端的算力信息通告，基于图论中心点理论和 Age of Information 指标值可以确定感知并更新实时信息最多的 1~2 个终端设备[17]]-[18]，作为关键终端设备(K)，由关键终端设备将三级终端设备的算力信息发送至二级终端设备，二级终端设备同样在自组织网内通告已知的算力信息，并确定关键终端设备，将信息发送至一级终端设备，一级终端设备在端侧算力网络内进行信息交互，进而汇聚全网算力信息，在受限的通信、感知、计算范围内得到算力信息更新度最大化的层次化端侧算力网络图。

3.2 面向多终端协同的资源虚拟化技术

端侧算力网络的一个重要特点就是需要多终端协同处理一个任务，不同的终端设备的硬件差异较大，资源虚拟化是将设备的硬件能力进行抽象，构建虚拟化资源池，实现不同设备之间的硬件能力共享，突破单一终端设备的处理能力的局限性，化零为整[19]。

同时，端侧算力网络能根据业务类型的不同，为用户匹配并选择能力合适的执行终端，让业务无缝地在不同设备之间流转，充分发挥不同设备的能力优势，如显示能力，摄像能力，音频能力，交互能力以及传感器能力等。比如在用户使用应用的过程中，当使用情景发生变化时（比如从室内走到室外，从车站到高速移动的车上），之前正在使用的设备可能就不再适合处理某些任务，或者当前所处环境周围有更合适的设备。那么，用户可以选择新的设备来继续执行当前任务，而利用这些新的设备来执行这些任务可以给用户带来当前环境下更好的用户体验。这种情况可以称为“跨端延续”或“跨端接连”。




图 7 多终端协同

而云终端的出现让广泛的终端可以更好的和云边协同，云终端作为一种专门利用云的虚拟资源进行计算处理的终端对于云边的虚拟资源的利用具有独特的优势和能力，可以说云终端的存在为终端的虚

拟资源和云边的虚拟资源的互通搭建起了一座桥梁[20]。

3.3 多终端协同的数据压缩技术

端侧算力网络可以加速智慧医疗、智慧家居、智慧城市、智能工厂、智能汽车等愿景的落地，实现这些智慧应用需要实时感知并传输泛在环境中的海量数据，海量数据通常为高清摄像设备获取的高分辨率视频，数据量的大幅增长对端侧算力网络中终端设备之间的通信容量提出了全新的挑战，为了在端侧算力网络中实现有效地数据传输，充分利用端侧算力网络中各个终端设备的有效算力资源，基于信息论、编解码理论、学习理论有效地压缩海量环境数据，将是端侧算力网络中的一项关键技术研究。近几年，随着深度学习理论研究的快速发展，其在数据压缩领域的优势也逐渐凸显，随机神经网络、卷积神经网络、递归神经网络、生成对抗网络、变分自动编码器等陆续被应用到数据压缩技术之中，利用深度学习模型的非线性映射能力，可以快速学习到海量数据的深层次特征，更加有效地去除掉冗余数据特征，进而满足海量数据压缩的需求，进而实现端侧算力网络中终端设备之间海量数据的低时延传输。

3.4 多粒度多层次端算力调度

由于终端设备具有算力较小，数量多的特点，对应一般的大型任务无法在一个终端上承载，就需要将大型任务的算力需求进行解构，满足终端设备的算力约束。同时终端设备种类繁多，不同种类的设备之间的算力资源差距较大，所以需要考虑多层次，多层级的算力调度

方案。

1. 算力解构




图 8 算力解构图

算力解构是将多样化,大粒度,复杂的算力需求,根据业务逻辑,资源需求,性能需求,服务持续性,业务流粘性,资源节点统一性等因素,分解成小粒度,简化的算力需求,使业务可以分布式地部署在多个终端算力节点上,突破单个设备资源能力有限的瓶颈,实现业务的灵活部署,资源的高效利用,同时实现任务的并行处理,大大缩短任务处理时延[21]。其中算力需求包括应用的 ID 信息,用来标识应用和用户信息;性能需求信息,如网络性能包括带宽,丢包率,安全性,稳定性等;计算需求信息,包括计算资源类型如 CPU,GPU,FGPA 芯片等。

结合应用的算力需求和当前的算力感知图,需要利用微服务等技术将单一的应用程序划分成一组适配于当前算力网络图的小的任务,

通过松耦合的通讯机制实现服务之间的互相协调，互相配合，聚合为用户提供最终价值[22]。

2. 多层次多级别算力调度

多层次的算力调度主要分为两个方面，分别是一个端侧算力网络内部的多层次调度和云边端协同的多层次调度[23]-[24]。

一个端侧算力网络内部根据算力大小级别进行分层次组网，由于某个设备上产生的业务大多都和该设备的算力级别相匹配，所以最开始匹配同层次的终端设备空闲算力资源进行调度；一旦业务的算力需求同级别算力的设备无法承载的时候则开始考虑更高算力级别的终端设备的空闲算力资源。

而云边端协同则是将端侧算力网络与算力网络相融合，因为端侧算力网络中设备数量巨大，设备具有普遍的异构性，而且大量终端设备属于用户私有设备。云边侧的服务器规模相对于端侧较小，设备异构性弱，且云服务器归企业所有。根据业务的不同需求可以将某些需要的算力大而且并需要安全保障的业务调度到云边的算力网络中，而将需要算力小，隐私需求高的业务限制在端侧算力网络中用户的私有设备上执行。

多个端侧算力网络之间可以分为多个级别，如家庭级的端侧算力网络，工业园区级的端侧算力网络等。相同级别的端侧算力网络中的业务相互的适配性更好，所以当在一个端侧算力网络内部无法实现满足该网络内设备所有任务的算力需求时，则将优先考虑相同级别端侧算

力网络之间的任务调度方案，一方面相同级别的端侧算力网络中的任务类型类似，硬件契合度更高，另一方面同一级别的算力网络之间的算力交易定价更加公平易于度量；具体将任务调度到哪个终端设备上则由其所在网络内部进行自主编排。

3.5 面向终端设备的现场级 AI 推理




图 9 个性化 AI 推理

设计更高准确率、更高效、更智能、且可以在 AIoT 终端设备上部署的现场级个性化 AI 推理模型[25]是端侧算力网络设计的一个关键技术。如上图所示，终端设备可以基于用户的使用习惯，更容易智能地提供具有差异性的智能化服务，既能保障用户隐私又提供用户智能感知推荐的服务。本地个性化网络数据往往样本较小且具有差异性，可以采用端侧小样本学习、迁移学习[26]、在线学习[27]等方法设计个性化的现场级 AI 推理模型，并采用模型压缩[28]、模型量化等方法将

模型部署在终端设备上，在端侧算力网络中进行联合学习。

3.6 端算力的定价机制

由于端侧算力网络中的终端设备的归属者包括个人、企业、运营设备商等，当用户需要借助其他用户的终端设备进行计算卸载时，不可避免会进行算力交易[29]，因此需要一套合理的算力交易的定价体系。

基于区块链工作量证明机制[30]的定价策略。根据区块链中的工作量证明机制，矿工需要购买更多的算力才能提高挖矿成功率，获得更多的奖励，这也意味着付出更高的成本代价，因此不同算力归属商之间出现了一个算力需求与定价博弈问题。算力提供者以最大化自己的利润为目标设定算力资源价格，而算力请求者以挖矿奖励最大化为目标，从供应商购买算力。为了解决这个问题，提出一个以博弈者的行为序列为基础，将算力提供者和算力请求者的算力交易建模为一个两阶段的 Stacklberg 博弈过程[31]，第一阶段，算力提供者设定算力资源价格，并向算力请求者收取计算卸载费用；第二阶段，算力请求者根据价格决定从算力提供者购买算力服务。

基于拍卖算法的算力资源定价策略[32]。首先算力提供者出价以及给出自己的算力资源总量，但是算力提供者在拍卖结束之前无法知道其他提供者所出的价钱以及计算资源总量，因此他只能根据自己的预期回报给出较为合理的价格。最后算力请求者从所有出价的算力提供者中选出优胜者并将计算任务卸载至出价优胜者处。

此外，还可制定其他的定价策略，如基于多智能体强化学习系统的模拟专业交易机制[33]等，都是可以进一步探索的技术和方法。

四、端侧算力网络的隐私与安全

4.1 认证与鉴权

终端设备身份认证和鉴权是一种终端设备的可信身份标识，具有不可篡改、不可伪造以及唯一的安全属性，是实现终端设备接入、确定责任归属以及防止恶意攻击的基础设施。因此需要对接入端侧算力网络的终端设备进行身份认证及鉴权。

终端设备在生产过程中会烧录一定的内容在 **flash** 中，来让设备证明自己的唯一与真实，这种情况下端侧算力网络会为终端设备分配设备 **ID** 与设备密钥。设备 **ID** 代表终端设备的唯一性，通常是一些唯一的字符串，以保证设备 **ID** 在算力网络中是唯一的。设备密钥代表了终端设备的真实性，设备密钥是设备的指纹，终端设备本身会携带，而在端侧算力网络中也有一份对应的密钥。此外，用户为终端设备发放算力令牌（**TOKEN**），具有设备 **ID** 和密钥、且获得算力令牌的终端可按照组网和调度算法纳入算力网络纳管，并进行周期性的更新、认证和鉴权，以防其被盗用。通常情况下，设备密钥有几种使用方式：终端设备密钥与端侧算力网络中的密钥相同；终端设备存储私钥，端侧算力网络存储公钥；终端设备存储公钥，端侧算力网络存储私钥。通过设备的密钥和存储在端侧算力网络中的密钥进行匹配和对比，可以实现终端设备的身份认证以及鉴权。

在认证和鉴权过程中，可以通过联邦和自治的方式，端设备共同选举出一些中心节点对端设备进行认证和鉴权，这些中心节点也可以

随着时间的推移和任务需求的变化而改变。由于端设备的异构性和复杂性，端设备之间的认证和鉴权相对于云计算和边缘计算会更加复杂，仍待进一步研究。

4.2 数据安全保护

端侧算力网络对隐私和安全的要求更高。在端侧可以借助多方安全计算[34]（MPC）、同态加密[35]（HE）以及区块链等技术，在不泄露敏感数据的前提下，对终端设备产生的数据进行分析计算，引入隐私计算，可以依托多方算力，分治计算任务，融合中间数据得到最终计算结果，实现算力服务对数据的可用不可见，为用户提供安全的计算服务。




图 10 安全计算流程示意图

隐私保护的限制使得许多含有隐私信息的数据无法被有效的利

用，隐私保护技术和数据共享之间的矛盾日益凸显，多方安全可以在一组互不信任的计算参与者之间进行协同计算，同时还能保护参与方的隐私。多方安全计算的原理图如上图所示。

每个参与方都有一个私有的输入数据，所有参与方在将数据加密之后共同计算某个函数，且要求在计算结束时，每个参与只能得到私有输入数据的输出，而不能得到其他参与方的输入信息与输出结果。多方安全技术主要通过同态加密技术、混淆电路（GC）、不经意传输（OT）和私密分享技术（SS）来进行保障。同态加密是一类具有特殊自然属性的加密方法，可以在密文域下进行数据运算的加密算法。混淆电路思想是利用计算机模拟集成电路的方式来实现多方安全计算，他将运算任务转化为门电路的形式，对每一条线路进行加密，可以有效保障用户的隐私安全。不经意传输技术是一种可保护隐私的秘密协议，他使得服务发送方和接收方以不经意的方式交互信息，从而达到保护隐私的目的。秘密分享也被称为秘密分割，是一种对秘密信息的管理方式，它将秘密进行拆分，拆分后的每一个分片由不同的参与者管理，单个参与者无法恢复秘密信息，需要超过一定门限数量的人一同协作进行合并才能恢复秘密文件。多方安全计理论主要解决的是各个数据参与者的信息保护和计算正确性问题，能够实现在无第三方的条件下，在保护数据不泄露的前提下保证计算的正确性。端侧算力网络中，多方安全计算可以让终端设备在不泄露敏感数据的情况下让自己产生的数据得到有效的计算。

4.3 可信交易

算力交易是指端侧算力提供者参与的可信交易模式[36]，算力网络通过搭建以平台型共享经济服务模式为核心，数字化网络为依托的算力服务运营交易平台，构建供给方和消费方的桥梁，盘活新建和存量算力资源。

当不同算力归属者之间发生任务卸载，即一个算力归属商向另外一个算力归属商提供算力时，算力交易不可避免地出现。根据区块链技术，提出以下算力交易模型如下图所示。




图 11 可信交易架构图

模型由边缘层和设备层组成，设备层的每个节点通过部署在边缘服务器上的可信授权代理完成注册，以获取合法身份标识和安全证书，并使用椭圆曲线加密算法[37]获取私钥，以生成账户地址加入区块链。

属于同一个归属者的终端设备之间进行任务卸载，不需要进行算力交易，而不同归属者之间进行任务卸载时，则会产生算力交易，算力提供者作为算力请求者提供算力服务，以实现计算卸载。边缘节点为整个系统提供广域监视和控制，进一步提高系统的安全性。在云挖掘机制的辅助下，算力请求者可以向算力提供者购买算力，并且将计算任务卸载到算力提供者处。

模型中的交易过程如下图所示，




图 12 可信交易流程图

由于一部分算力提供者可能由于网络波动以及自身任务占用抑或是恶意出价，导致算力请求者卸载过来的计算任务无法按时按量的

完成,因此需要建立一个完备的交易评价体系和算力提供者信誉积分体系[38],在算力交易结束后对此次交易进行打分,并对算力提供者的信誉积分进行评估,对于那些信誉积分较低的算力提供者,将会禁止其进行算力交易。

五、端侧算力网络的应用场景

5.1 智能家居




图 13 智能家居

智能家居通过物联网技术将家中的各种设备连接到一起，提供家电控制、照明控制、电话远程控制、室内外遥控、防盗报警、环境监测、暖通控制、红外转发以及可编程定时控制等多种功能和手段。由于智能家居的强安全隐私需求，各种任务的处理往往是在本地执行，这会带来高时延和低算力利用效率的缺陷。因此为了进一步提升住户体验，可以引入端侧算力网络，将时延敏感型或者计算密集型任务调度到适当的设备上进行处理，因为任务在家庭中的设备上处理，不会经过外网，可以在保证隐私不被泄露的前提下提升服务的质量。

智能家居中的端侧算力网络还可以实现业务的跨端迁移从而更好的利用不同设备的优势功能给用户以最好的体验，比如用户可以通过

过端侧算力网络将自己手机上播放的视频迁移到高清大显示屏上，将邮件编辑相关的业务迁移到平板上，将音频业务迁移到高性能耳机上播放，实现不同设备之间的硬件能力共享。其次，针对安防系统中摄像头拍摄的视频流可以迁移到智能家居中闲置的设备比如空调，智能音响等设备进行存储和处理，并将结果返回给安防系统，这样可以减轻智能摄像头的业务压力，通过业务分流，缩短任务处理时延，提高终端设备的算力利用率。还可以在智能家居中通过实现个性化深度强化学习来更好地为人服务，比如说智能家居中空调温度的自动调节，可以根据当前室内温度，湿度，时间，室内人的穿衣情况通过以往室内主人调节温度的行为训练更加个性化的模型来自适应的调节温度[39]。

5.2 智能医疗




图 14 智慧医疗

在新冠疫情的影响下，线上医疗得到了迅速的发展，国家全面推进互联网诊疗以减少交叉感染的风险[40]。相比线下门诊，在线问诊，线上医疗需求大幅提升。患者的病历以及相关的健康数据对用户来说是隐私数据，设备直接采集患者的数据并上传到云端处理则容易造成隐私泄露，给患者造成困扰。采用端侧算力网络则可以将患者的敏感数据传输到网络中的可信设备进行脱敏处理，以达到保护患者的目的。随着各式各样的终端设备和智能终端的蓬勃发展，各类高度集成的可穿戴设备可以实时地收集个人的健康数据，并且可以将数据上传至端侧算力网络，同时通过对个人隐私数据进行脱敏和加密，实现数据实时存储分析处理并且保证用户的隐私和安全。通过各类可穿戴的终端设备组合，构成专注于个人健康的智慧医疗系统[41]。通过终端设备获取的真实世界数据与电子病历相结合，实现院内与院外的全周期健康管理。各类非接触式传感器的普及，让以家庭为单位的健康监测成为可能。

通过对以跌倒监控器、家用血压计、婴儿呼吸监测仪、非接触睡眠监测仪等为代表的非接触式传感器的设置，并结合可穿戴设备和网关设备等，组建用于健康监测的端侧算力网络，可以实现对家庭成员的各项健康指标的实时监控。例如，通过跌倒传感器、声音传感器以及边缘网关相结合的方式，可以很好地监控老人跌倒情况，一旦老人跌倒或呼救，传感器通过视觉深度、陀螺仪、声音分析等方式检测到后立即传输至网关，并经由网关连通至老人所在地社区的卫生服务信

息系统以及最近的医院急救系统，以最快的速度为老人提供急救措施。

5.3 车联网




图 15 车联网

智能车辆的算力在 6G 网络愿景和自动驾驶业务的驱动下升级显著，智能车辆终端、路侧监控终端、道路指示灯终端等可以组建成一个动态变化的区域自治端侧算力车联网络[42]。

车辆在行驶过程中可能由于无法获取视距外的道路交通信息而处于危险之中，在端侧算力车联网络中，终端设备可以基于分布式一致性协议进行数据信息的协同，周围车辆可以获取危险车辆位置周边的路况交通信息[43]，并利用周围车辆的算力进行信息处理，向危险车辆发出预警信息，辅助车辆安全行驶。

当一个智能车辆终端算力资源不充足时，端侧算力车联网络可以根据各个终端的算力状态，将资源匮乏的智能车辆的业务调度至资源充足的智能车辆，实现终端智能共享算力资源。

当车辆终端由于行驶速度、行驶方向的差异无法进行通信时，端侧算力车联网络可以实时更新网络状态，组建新的端侧算力网络。

5.4 智慧教育



图 16 云终端在多媒体教育中的应用

多媒体教室使用传统的主机无论是成本还是软、硬件维护，数据安全上都难以管理和保护，比如当操作系统升级时，每台电脑都要手动去安装系统软件或者升级。而且使用传统的主机随着时间的推移，PC 上的 CPU、内存、硬盘、显卡、电源、主板、风扇等部件都存在升级和损坏的可能，这些都需要维护更换。同时使用传统的主机因为包含 USB 和软驱即外来的接口，需要不断升级而且容易通过 U 盘带来病毒攻击。为了省去这些繁琐的过程并且便于管理，可以使用云终端，只需管理好服务器端即可，具体的数据隐私安全保护和系统升级等都由运营商来维护管理，可以保证性能稳定，节省成本资源[44]。作为算力网络资源的使用者，通过多层次多粒度端侧算力调度和面向多终端协同的资源虚拟化，云终端可以作为中继节点和其他终端相互

协同，促进端侧算力网络资源和算力网络资源之间的协同共享，从而获得更高的效益。

5.5 智慧农业



图 17 智慧农业

近些年，随着物联网技术、音视频技术、无线通信技术以及 3S 技术的进步，智慧农业开始走进我们的生活之中，并备受政府以及产学研界的关注。智慧农业通过部署众多不同功能的传感器收集作物的生长数据、土壤数据、环境数据以及气象数据，将传感器收集的数据通过农田内安置的基站传输至云端，运用大数据、人工智能等技术进行智能分析并做出管理决策。除此之外，智慧温室大棚中的还需要安装加温补光、内外遮阳、风机、滴水灌溉、水肥一体化设备，并需要对这些设备做出精准控制以及监测设备的运行状态。目前，智慧农业模式传感器数据传输至中心云通常时延较长，无法满足农作物生长对

于实时温湿度敏感的特性。与此同时,智慧农业园区中的智能摄像头、温控设备、智能网关、采摘机器人等设备都已经具备一定的通信与计算能力,并且智慧农业中的供电设备可以通过太阳能进行供电,具备绿色节能的优势。因此,在智慧农业园区中建立端侧算力网络,充分利用智慧农业园区的终端设备的算力资源,将传感器、摄像头采集的数据传输至采摘机器人、智能网关、工作人员的手机等终端设备中,并通过多个终端设备协同分析,可以快速做出设备控制决策,并充分利用园区的太阳能资源,通过长期的数据分析赋能我国农业稳步健康发展。

六、结束语

端侧算力网络是算力网络的重要组成部分。端侧算力网络充分利用分布式多级终端侧算力资源，通过构建高效的端侧算力体系架构和新型网络范式，实现端侧算力感知、资源虚拟协同、多粒度算力调度以及安全隐私与可信交易，进而显著增强终端侧新型算力的利用能力。

本白皮书从端侧算力的有效利用的角度出发，介绍了终端的发展背景、端侧算力网络的概念及架构、关键技术等主要内容，并分析了其隐私与安全性能，给出了端侧算力网络的主要应用场景，为端算力技术研究及实际网络演进与发展提供参考。通过本白皮书，助力加快国家算力网络战略、前沿技术和应用的发展，凝聚学术界和产业界共识，推进端侧算力网络技术加快发展并走向商业成熟。

参考文献

- [1] Cisco U. Cisco annual internet report (2018–2023) white paper. 2020[J]. Acessado em, 2021, 10(01).
- [2] <https://www.scensmart.com/general-description-of-soc/rockchip-rk3566/>
- [3] https://www.t-firefly.com/product/coreboard/core_1808_jd4.html?theme=pc
- [4] <https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=15>
- [5] <https://e.huawei.com/cn/products/cloud-computing-dc/atlas/ascend-910>
- [6] J. Peng, H. Qiu, J. Cai, W. Xu and J. Wang, "D2D-Assisted Multi-User Cooperative Partial Offloading, Transmission Scheduling and Computation Allocating for MEC," in *IEEE Transactions on Wireless Communications*, vol. 20, no. 8, pp. 4858-4873, Aug. 2021.
- [7] L. U. Khan, W. Saad, Z. Han, E. Hossain and C. S. Hong, "Federated Learning for Internet of Things: Recent Advances, Taxonomy, and Open Challenges," in *IEEE Communications Surveys & Tutorials*, vol. 23, no. 3, pp. 1759-1799, thirdquarter 2021.
- [8] 36 氪. 智能硬件终端行业研究报告[R], 2019.
- [9] S. Wang, X. Zhang, Y. Zhang, L. Wang, J. Yang and W. Wang, "A Survey on Mobile Edge Networks: Convergence of Computing, Caching and Communications," in *IEEE Access*, vol. 5, pp. 6757-6779, 2017.
- [10] 计世资讯. 中国云终端市场发展报告[R], 2022.
- [11] J. Liu, Y. Sun, J. Su, Z. Li, X. Zhang, B. Lei and W. Wang, " Computing Power Network: A Testbed and Applications with Edge Intelligence," *IEEE INFOCOM 2022 - IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS)*, 2022, pp. 1-2.
- [12] Y. Sun, J. Liu, H. Huang, X. Zhang, B. Lei, J. Peng, W. Wang, "Computing Power Network: A Survey", submitted to China Communications.
- [13] X. Dai *et al.*, "Task Co-Offloading for D2D-assisted Mobile Edge Computing in Industrial Internet of Things," in *IEEE Transactions on Industrial Informatics*, doi: 10.1109/TII.2022.3158974.

- [14] H. Long, C. Xu, G. Zheng and Y. Sheng, "Socially-Aware Energy-Efficient Task Partial Offloading in MEC Networks with D2D Collaboration," in *IEEE Transactions on Green Communications and Networking*, doi: 10.1109/TGCN.2022.3153956.
- [15] L. Zhang and J. Xu, "Differential Security Game in Heterogeneous Device-to-Device Offloading Network Under Epidemic Risks," in *IEEE Transactions on Network Science and Engineering*, vol. 7, no. 3, pp. 1852-1861, 1 July-Sept. 2020.
- [16] M. Chen, H. Wang, D. Han and X. Chu, "Signaling-Based Incentive Mechanism for D2D Computation Offloading," in *IEEE Internet of Things Journal*, vol. 9, no. 6, pp. 4639-4649, 15 March 2022.
- [17] 孙钰坤, 张兴, 雷波. 边缘算力网络中智能算力感知路由分配策略研究[J]. 无线电通信技术, 2022, 48(01): 60-67.
- [18] A. A. Al-Habob, O. A. Dobre and H. V. Poor, "Age- and Correlation-Aware Information Gathering," in *IEEE Wireless Communications Letters*, vol. 11, no. 2, pp. 273-277, Feb. 2022.
- [19] 鲜领. 分布式异构无人系统资源虚拟化技术研究及验证[D]. 四川: 电子科技大学, 2021.
- [20] 马学伟. 云计算与云终端在高校中的应用[J]. 无线互联科技, 2020, 17(18): 148-149.
- [21] 龙隆, 刘子辰, 石晶林, 等. 移动边缘计算中计算卸载与资源分配的联合优化策略[J]. 高技术通讯, 2020, 30(8): 765-773.
- [22] 邓欣. 微服务架构在分布式系统的设计和应用[J]. 品牌研究, 2020(33): 102.
- [23] 刘泽宁, 李凯, 吴连涛, 等. 多层次算力网络中代价感知任务调度算法[J]. 计算机研究与发展, 2020, 57(9): 1810-1822.
- [24] L. Junlin, Z. Xing, et al., "Energy-Efficient Computation Offloading for Mobile Edge Networks: A Graph Theory Approach", in *IEEE/CIC ICC*, Xiamen, China, Jul. 2021.
- [25] S. Yukun, Z. Xing, and Z. Yongdong, "Mobility and traffic Prediction-Based resource allocation with edge intelligence in wireless network," in *2021 13th*

International Conference on Wireless Communications and Signal Processing (WCSP'21), Changsha, China, Oct. 2021.

[26] M. Wang, Y. Lin, Q. Tian and G. Si, "Transfer Learning Promotes 6G Wireless Communications: Recent Advances and Future Challenges," in *IEEE Transactions on Reliability*, vol. 70, no. 2, pp. 790-807, June 2021.

[27] Hoi S C H, Sahoo D, Lu J, et al. "Online learning: A comprehensive survey," in *Neurocomputing*, 2021, 459: 249-289.

[28] Bertheliet A, Chateau T, Duffner S, et al. "Deep model compression and architecture optimization for embedded systems: A survey," in *Journal of Signal Processing Systems*, 2021, 93(8): 863-878.

[29] 雷波,赵倩颖.CPN:一种计算/网络资源联合优化方案探讨[J].数据与计算发展前沿,2020,2(04):55-64.

[30] 沈哲鑫.基于区块链的碳抵消研究综述与展望[J].中国商论,2022(04):112-115.

[31] 吴雨芯,蔡婷.移动边缘计算中基于 Stackelberg 博弈的算力交易与定价[J].计算机应用,2020,40(9):2683-2690.

[32] 郑阳超,李珍妮.面向资源最优分配的深度学习双边拍卖算法[J/OL].控制理论与应用:1-10[2022-05-17].

[33] C. T. Chen, A. Chen and S. Huang, "Cloning Strategies from Trading Records using Agent-based Reinforcement Learning Algorithm," *2018 IEEE International Conference on Agents (ICA)*, 2018, pp. 34-37.

[34] 潘无穷,李婷婷,韦韬,张煜龙,段然,钱中天,李天一. 分布式多方安全计算系统、方法和节点[P]. 浙江省: CN113992439B,2022-05-06.

[35] 王腾,霍峥,黄亚鑫,范艺琳.联邦学习中的隐私保护技术研究综述[J/OL].计算机应用:1-15[2022-05-17].

[36] 迟占博,张勖,李婧,邵苏杰,王东滨.基于区块链的可信交易完备性模式设计[J].信息安全研究,2022,8(05):460-467.

[37] 高思. 加密算法在电子身份标识中的应用[D].北京化工大学,2021.

[38] 曹萱. 基于区块链技术的分布式能源交易平台架构设计与实现[D].北京邮电

大学,2021.

[39] 古秋祥,罗朝晖,索凯,等. 智能家居[J]. 科技风,2019(24):15.

[40] 刘梦祺.我国互联网医疗发展的现实困境及立法对策探析——兼评《互联网诊疗管理办法(试行)》等三份文件[J].西南大学学报(社会科学版),2022,48(02):37-48.

[41] 孙海波,齐顺利,孙平,于晓倩.智慧医疗系统设计与实现[J].网络安全技术与应用,2021(10):130-131.

[42] F. Tang, B. Mao, N. Kato and G. Gui, "Comprehensive Survey on Machine Learning in Vehicular Network: Technology, Applications and Challenges," in *IEEE Communications Surveys & Tutorials*, vol. 23, no. 3, pp. 2027-2057, thirdquarter 2021.

[43] A. Talpur and M. Gurusamy, "Machine Learning for Security in Vehicular Networks: A Comprehensive Survey," in *IEEE Communications Surveys & Tutorials*, vol. 24, no. 1, pp. 346-379, Firstquarter 2022.

[44] 王清勇,王宏. 云终端在高校机房建设中的应用[J].中国高新区,2019(11):31.

缩略语

缩略语	英文全称	中文含义
5G	5th Generation Mobile Networks	第五代移动通信
6G	6th Generation Mobile Networks	第六代移动通信
AI	Artificial Intelligence	人工智能
AIoT	Artificial Internet of Things	智能物联网
API	Application Programming Interface	应用程序接口
APP	Application	应用程序
ARM	Advanced RISC Machine	RISC 微处理器
CPU	Central Processing Unit	中央处理器
DPU	Data Processing Unit	数据处理器
D2D	Device to Device	设备到设备的通信
FPGA	Field Programmable Gate Array	现场可编程门阵列
FLOPS	floating-point operations per second	每秒执行的浮点运算次数
GC	Garbled Circuit	混淆电路
GPU	Graphic Processing Unit	图形处理器
HE	Homomorphic Encryption	同态加密
IDC	Internet Data Center	互联网数据中心
I/O	Input/Output	输入输出

IoT	Internet of Things	物联网
MPC	Secure Multi-party Computation	多方安全计算
NPU	Neural-Network Processing Unit	嵌入式神经网络处理器
QoS	Quality of Service	服务质量
RISC	Reduced Instruction Set Computer	精简指令集计算机
OT	Oblivious Transfer	不经意传输
SS	Secret Sharing	私密分享
TCAN	Terminal Computing Aware Network	端侧算力网络
TOPS	Tera Operations Per Second	每秒操作一万亿次
UWB	Ultra Wide Band	超宽带技术
XR	Extended Reality	扩展现实
X86	The X86 Architecture	X86 计算机指令集